長庚大學資訊工程學系

智慧相簿管理系統

系統測試成果報告

指導教授：吳世琳教授_____

陳嶽鵬教授_____

計畫參與人員:

資工系:

B1228015　湯依儒

B1228018　蔡佩妤

人工智慧學系:

B1228006　鄭暐薰

B1228021　邱庭俞

中華民國 115 年 11 月

目錄

1. 測試計畫名稱與編號 3

2. 簡介 3

2.1 計畫目的 4

2.2 計畫範圍 5

2.3 參考文件 6

3. 測試項目 7

3.1 操作測試 7

3.2 功能測試 9

3.2.1 照片掃描與特徵建立（F1） 9

3.2.2 以文字搜尋照片與篩選（F2） 9

3.2.3 自動主題分類（F3） 10

3.2.4 人像判斷（F4） 11

3.2.5 單據與票券辨識（F5） 12

3.2.6 自動回憶相簿（F6） 13

3.2.7 專屬相簿：我的 IP（F7） 13

3.2.8 AI 助理整理（F8） 14

3.2.9 隱私與資料管理（F9） 15

3.2.10 抽象語意搜尋（F10） 15

3.3 介面測試 16

3.4 績效測試 18

3.5 品質測試 19

4. 測試方法 21

4.1 測試環境需求 22

4.2 測試項目的通過準則 23

4.3 測試中止的準則與再繼續的需求 24

4.4 測試交付項目 24

5. 人員配置與訓練需求 *25*

5.1 測試人員配置 **25**

5.2 訓練需求 **25**

6. 測試結果與審查 *26*

6.1 測試結果摘要 **26**

6.2 自動分類準確率評估結果 **27**

6.3 抽象語意搜尋評估結果 **29**

6.4 開發期間發現的問題與處理 **32**

6.5 審查結論與後續改善 **34**

1. 測試計畫名稱與編號

項目	內容
測試計畫名稱	selfIE 智慧相簿管理系統　系統測試計畫
測試計畫編號	SELFIE-STP-115-01
文件版本	2.0（115 年 11 月）
受測系統	selfIE（iPhone App）：自動整理手機照片的智慧相簿，名稱中的 I 代表 Image（影像）、E 代表 Evaluate（評估）
受測版本	115 年 11 月專題展示版
測試期間	115 年 2 月 23 日至 115 年 11 月 20 日
測試類型	操作測試、功能測試、介面測試、績效測試、品質測試

2. 簡介

手機相簿動輒上千、上萬張照片，使用者想找「去年在海邊看夕陽的照片」或「上次吃拉麵時拍的菜單」時，往往只能靠記憶一直往上滑。selfIE 是一款 iPhone 智慧相簿 App，我們的 Slogan 是「自動整理你／妳拍下的瞬間」。它在手機上用影像辨識模型理解每張照片的內容，讓使用者可以：

（1）**用一句話找照片**：輸入「海邊的夕陽」、「桃園市」、「2025 年 8 月」、「2025/8」等文字，就能找到相關照片，並可再依時間、地點篩選。

（2）**自動分類成主題相簿**：照片會自動歸入 15 個大分類、122 個小分類（例如美食的「麵食」、動物的「貓」、收藏的「專輯與周邊」），不需要手動建立相簿。

（3）**自動產生回憶相簿**：自動找出旅行、演唱會場次，整理成「東京 8/22–8/25」這類相簿。

（4）**讀懂票券與單據**：讀取照片上的文字，分辨電影票根、收據發票、登機

證與菜單。

（5）**AI Agent**： AI Agent 能分析使用者拍攝的照片，整理其中的知識並儲存為筆記，同時依照使用者偏好整理內容，透過語意檢索找出相關筆記，協助使用者管理與延伸個人知識。

（6）**AI 整理**：把旅行照片整理成回憶筆記，把拍下的商品、想去的店家整理成購物清單與想去清單。

（7）**抽象語意搜尋**：輸入一句描述畫面情境的話，例如「一隻在海邊散步的狗」、「兩個人在房間聊天」、「溫馨的家庭聚餐」，系統會理解並解析語句中的主體、數量、動作、關係與情緒氛圍等內容，找出符合的照片，且不需要剛好說中照片的標籤。

selfIE 的主要特色是隱私。照片的辨識與分類都在手機上完成，不會上傳。App 只讀取照片，不會修改、移動或刪除使用者原本的照片與相簿。唯一可能把照片送出手機的是 AI Agent 功能，且第一次使用前會先徵求使用者同意。

2.1 計畫目的

本測試計畫的目的，是以明確、可量測的標準驗證 selfIE 是否達到設計目標，並記錄測試結果作為後續改善依據。具體目的如下：

（1）確認第 2.2 節列出的 10 項核心功能都能依設計正確運作。

（2）以明確數值（KPI）評估系統的反應時間、辨識準確率與穩定性，判斷是否達到可展示、可供一般使用者操作的水準。

（3）確認系統在任何操作下都不會修改或刪除使用者的原始照片，且隱私相關設計（照片留在手機、使用 AI 助理前需同意）確實有效。

（4）找出準確率不足或容易誤判的地方，提出具體的改善方向。

2.2 計畫範圍

下表列出每項功能在第 3 章對應的測試項目編號，計畫範圍與測試範圍一一對應：

表 2-1　測試範圍與對應測試項目

代號	功能	說明	對應測試項目
F1	照片掃描與特徵建立	讀取手機相簿，替每張照片計算「影像特徵」（可比對內容的向量），新照片自動加入	OP-01～03、FT-1、PF-03、QA-08
F2	以文字搜尋照片與篩選	用自然語言、日期（「2025 年 8 月」「2025/8」都可以）或地名找照片，輸入國家名會找出整個國家的照片；結果可依年份、月份、旅行、國家地區篩選，篩選選項會依已選的條件連動，並可排除截圖；照片頁可切換「全部／截圖」	FT-2、PF-01、PF-02、QA-04
F3	自動主題分類	把照片自動歸入 15 個大分類、122 個小分類；以使用者標記與公開資料集（Open Images V7、Places365、Food-101）訓練的分類判斷器，搭配文字描述比對；使用者回答「是／不是」後會越來越準	FT-3、PF-04、QA-01
F4	實體人物判斷	「自拍」直接採用 iPhone「照片」App 的「自拍」相簿；「人物照」判斷照片主角是不是人，周邊、海報、看板與螢幕上的人不算	FT-4、QA-02
F5	單據與票券辨識	讀取照片上的文字，分辨收據發票、登機證與菜單；電影票根依文字歸入「電影」分類	FT-5、PF-05、QA-03
F6	自動回憶相簿	依拍攝時間與地點，自動找出旅行與演唱會場次並建立相簿	FT-6、QA-05

代號	功能	說明	對應測試項目
F7	專屬相簿（我的 IP）	使用者挑幾張範例照片（例如某個角色的周邊），系統找出相似的照片	FT-7、QA-06
F8	AI 助理整理（App 端）	把照片整理成回憶筆記、想去清單、購物清單；可選擇用手機上的 Apple Intelligence 或開發者的後端（後端本身不在本人範圍）	FT-8、PF-08、QA-11
F9	隱私與資料管理	只讀取不修改照片；可移除 AI 分析資料；同步系統「刪除」與「喜好項目」	FT-9、OP-04、QA-09、QA-10、QA-12
F10	抽象語意搜尋	把照片轉成 Graph 結構（主體、關係、場景與氛圍）存入資料庫，用一句話描述畫面情境就能找到照片；文字型照片則是使用 F1、F5 的結果	FT-10、PF-11～PF-13、QA-13～QA-15

測試項目編號的意義：OP 為操作測試、FT 為功能測試、UI／IF 為介面測試、PF 為績效測試、QA 為品質測試。

不在本次範圍內的項目：

（1）iPhone 以外的平台（iPad 版面、Android）。

（2）多台手機之間的資料同步。

2.3 參考文件

（1）Kuznetsova, A. et al. (2020). The Open Images Dataset V4. International Journal of Computer Vision, 128, 1956–1981；Open Images V7 資料集網站（分類判斷器的訓練與驗證資料）。

（2）Vasu, P. K. A. et al. (2024). MobileCLIP: Fast Image-Text Models through Multi-Modal Reinforced Training. CVPR 2024（手機上的影像與文字比對模型）。

（3）Apple Developer Documentation：Photos（PhotoKit，唯讀存取照片）、Vision（文字辨識）、Foundation Models（手機上的 Apple Intelligence 語言模型）、 Natural Language（NLContextualEmbedding，手機上的文字向量） 。

（4）Zhou, B. et al. (2018). Places: A 10 Million Image Database for Scene Recognition. IEEE Transactions on Pattern Analysis and Machine Intelligence, 40(6), 1452–1464（場景類分類判斷器的訓練與驗證資料）。

（5）Bossard, L., Guillaumin, M., & Van Gool, L. (2014). Food-101 – Mining Discriminative Components with Random Forests. ECCV 2014（美食類分類判斷器的訓練與驗證資料）。

3. 測試項目

本章依測試類型列出所有測試項目。每個功能測試都有測試條件、測試步驟、預期結果與 Pass／Fail 標準；績效與品質測試則列出 KPI 的量測方式與目標值。除非另外說明，測試都在第 4.1 節的測試環境、以「測試相簿」進行。

3.1 操作測試

操作測試從使用者的角度，確認第一次使用到日常操作的流程順暢、不會卡住或出錯。

表 3-1　操作測試項目

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
OP-01	剛安裝的 App；手機相簿有照片	1. 開啟 App 2. 分別選擇「允許完整存取」「部分存取」「不允許」三種權限各測一次	完整、部分存取：自動開始掃描並顯示進度；不允許：顯示說明與前往設定的按鈕，App 不會當機	3 種權限各 1 次，3/3 符合預期
OP-02	首次掃描進行中	1. 打開「整理進度」 2. 按「暫停掃描」 3. 等 10 秒後按「立即掃描」	暫停後進度數字不再增加；繼續後從暫停的地方接著掃，不從頭開始	連續測 5 次，5/5 符合；進度不歸零
OP-03	掃描或分析進行中	1. 切換到其他 App 或鎖定螢幕 2. 1 分鐘後回到 App	回到 App 後自動接續，已完成的照片不重算	5/5 次自動接續
OP-04	已有 100 張照片完成掃描	1. 在照片頁按愛心加入最愛 2. 在 iPhone「照片」App 把另一張設成喜好項目 3. 回到 App 的「最愛」分頁	App 內按的最愛立即出現；「照片」App 的喜好項目在 3 秒內同步出現	10 次操作中 10 次在 3 秒內出現
OP-05	照片辨識與分析正在背景進行	1. 開啟低耗電模式 2. 關閉低耗電模式	開啟時暫停文字辨識；關閉後自動接續	3/3 次符合
OP-06	「設定」頁	1. 切換 AI 處理方式（手機上／開發者後端） 2. 開關「同步喜好項目」 3. 重新開啟 App	設定立即生效，重開 App 後仍保留	每項設定 3/3 次保留

3.2 功能測試

功能測試依第 2.2 節的 10 項核心功能（F1～F10）分節。「測試相簿」與各功能使用的測試照片集見第 4.1 節。

3.2.1 照片掃描與特徵建立（F1）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-1-1	首次授權後；測試相簿 10,000 張照片	1. 授權完整存取 2. 等待掃描完成 3. 比對 App 已處理張數與相簿張數	所有手機上的照片都完成掃描	已處理張數 ＝ 相簿張數（100%）
FT-1-2	首次掃描已完成	1. 用相機拍 5 張新照片 2. 回到 App	新照片自動掃描並可被搜尋、分類	5/5 張在 1 分鐘內可被搜尋到
FT-1-3	有 20 張照片只存在 iCloud（未下載到手機）	1. 執行掃描 2. 觀察網路用量與結果	只使用手機上的縮圖處理，不會自動下載原圖	下載原圖 0 張；20/20 張以縮圖完成或標示待處理

3.2.2 以文字搜尋照片與篩選（F2）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-2-1	測試相簿；20 組事先標好答案的查詢（如「海邊的夕陽」「貓在沙發上」）	1. 在首頁搜尋框輸入查詢 2. 檢查前 20 張結果	前 20 張結果大多為符合描述的照片	見 QA-04：Recall@20 ≥ 80%
FT-2-2	相簿含 2025 年 8 月的照片	分別輸入「2025 年 8 月」與「2025/8」	只出現該月份的照片；兩種寫法結果相同	結果中非該月份照片 0 張
FT-2-3	相簿含在桃園市拍的照片	輸入「桃園市」	自動套用「桃園市」地點篩選，結果都在桃園市拍攝	結果中地點不符 0 張；篩選自動套用 1/1

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
FT-2-4	任一有結果的查詢	依序套用年份、月份、某次旅行、國家／地區、排除截圖篩選	每種篩選只列出結果中實際有的選項並附張數；套用後張數與選項標示相同	5 種篩選 5/5 張數一致
FT-2-5	查詢「火星上的企鵝」等相簿中沒有的內容	輸入查詢	顯示「找不到」的提示，不當機	3/3 次正確提示
FT-2-6	相簿含在泰國多個城市（曼谷、清邁等）拍的照片	1. 輸入「泰國」 2. 輸入某個月份（如「2025 年 8 月」）後開啟地點篩選	找出在泰國各地拍的照片，不只名稱叫「泰國」的單一地區；地點篩選只列出該月份實際拍過照片的國家地區	泰國照片漏掉 0 張；地點選項中該月沒拍過的地點 0 個
FT-2-7	相簿含螢幕截圖	1. 在照片頁點「截圖」 2. 再點「全部」	「截圖」只列出 iPhone 標記為螢幕截圖的照片並附張數；切回「全部」顯示所有照片	截圖張數與「照片」App 的「螢幕截圖」相簿相同；混入非截圖 0 張

3.2.3 自動主題分類（F3）

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
FT-3-1	測試相簿完成掃描	隨機抽 200 張照片，檢查每張的自動分類	每張最多 3 個自動分類；顯示在對應主題相簿	200/200 張自動分類 ≤3 個
FT-3-2	某張照片被自動分到錯的分類（例如貓）	1. 在「待確認」或照片頁回答「不是」 2. 找 5 張和它幾乎一樣的照片（同一組連拍）	相似照片也不再被分到該分類	5 張相似照片中 ≥ 4 張被移出

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-3-3	使用者手動加入或移除過的分類	1. 手動把一張照片加入「蛋糕」 2. 觸發重新分類（更新分類設定後重開 App）	手動結果保留，不被自動結果覆蓋	10/10 張手動結果保留
FT-3-4	拍攝餐廳菜單、手寫筆記各 10 張（上面寫有「牛肉麵」等菜名）	掃描並完成文字辨識後檢查分類	不會被分到「麵食」等菜色分類	20 張中誤分為菜色 0 張
FT-3-5	玩偶、小卡與壓克力立牌（專輯與周邊）、公仔、印有動物圖案的商品各 10 張	檢查動物分類	不會被分到「貓」「狗」等動物	40 張中誤分為動物 ≤2 張（≤ 5%）

3.2.4 人像判斷（F4）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-4-1	人工標好答案的 200 張照片（同 QA-02）	完成分類後，比對 App 的「自拍」「人物照」與答案	自拍、人物照分到正確分類；有人像但不是人物照的照片不被標成人物照	見 QA-02：Accuracy ≥ 85%
FT-4-2	前鏡頭自拍 20 張（在 iPhone「自拍」相簿中）與後鏡頭人物照 20 張	比對「自拍」分類	「自拍」與 iPhone「照片」App 的「自拍」相簿一致；後鏡頭的人物照不算自拍	40/40 張判斷正確

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
FT-4-3	偶像小卡、海報、路邊看板、電視畫面翻拍各 10 張（照片中有人）	檢查「人物照」分類	印刷品、看板或螢幕上的人不算人物照	40 張中誤分為人物照 ≤4 張（≤ 10%）
FT-4-4	「自拍」相簿中的照片 20 張	檢查自動分類	只標「自拍」，不重複標「人物照」	20/20 張沒有同時標成人物照

3.2.5 單據與票券辨識（F5）

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
FT-5-1	電影票根 20 張	完成文字辨識後檢查分類	分到「電影」	見 QA-03：Recall ≥ 80%
FT-5-2	收據、發票 20 張	同上	分到「收據發票」	同上
FT-5-3	紙本登機證 10 張、手機錢包登機證截圖 10 張	同上	都分到「機票與登機證」（截圖也算）	同上
FT-5-4	訂票網頁截圖 10 張（有座位、場次文字）	同上	訂票頁面截圖不算電影票根或收據	10 張中誤判 0 張
FT-5-5	一般文件、筆記、黑板 40 張（非單據）	同上	不會被分到電影、收據、登機證	見 QA-03：Precision ≥ 95%

3.2.6 自動回憶相簿（F6）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-6-1	測試相簿含人工標記的 10 次旅行（離家 ≥40 公里、≥2 天）	開啟「時間與地點」相簿	每次旅行產生一本相簿，名稱含地點與日期（如「東京 8/22–8/25」）	見 QA-05：F1 ≥ 80%
FT-6-2	住家、學校附近 30 天內的日常照片	同上	常去地點不會被當成旅行	產生錯誤旅行相簿 0 本
FT-6-3	2 場演唱會的照片	開啟「演唱會」相簿	每一場整理成一個場次	2/2 場正確分組

3.2.7 專屬相簿：我的 IP（F7）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-7-1	相簿中有某角色周邊照片 50 張與無關照片	1. 新增專屬相簿，挑 5 張範例 2. 等待比對完成	非常像的照片自動加入，有點像的列為「待確認」	見 QA-06：自動加入 Precision ≥ 85%
FT-7-2	FT-7-1 完成後	對「待確認」照片回答「是 / 不是」各 10 張	回答後重新比對，「不是」的類似照片不再出現	回答「不是」的照片 0 張再出現
FT-7-3	照片上印有角色名稱文字（包裝、看板）10 張	建立同名的專屬相簿	有名稱文字的照片列入待確認或自動加入	10 張中 ≥8 張被找到

3.2.8 AI 助理整理（F8）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-8-1	一次 3 天的旅行相簿（30 張照片）；AI 處理方式選「手機上」	按「整理成回憶筆記」	產生依日期整理的繁體中文筆記，內容與照片相符	3/3 次成功產生；內容錯誤（照片中沒有的地點或價格）0 處
FT-8-2	在店家、景點拍的照片 10 張	加入「想去清單」	辨識店名與地點，同一品牌與分店合併為一筆；依地區分成不同筆記	10 筆中店名或地點正確 ≥8 筆；重複項目 0 筆
FT-8-3	FT-8-2 的清單	點選地圖連結，分別用 Google 地圖與 Apple 地圖開啟	兩種地圖顯示同一個地點	10/10 筆位置一致
FT-8-4	商品照片 10 張（含韓國、日本的商品標示）	加入「購物清單」	列出商品名稱、價格與國家；價格只取照片上有貨幣符號的數字	名稱正確 ≥8/10；捏造的價格 0 筆
FT-8-5	從未使用過 AI 助理	第一次點選下方「Agent」分頁	先顯示隱私說明與同意畫面；不同意就不送出任何照片	1/1 次顯示；不同意時送出照片 0 張
FT-8-6	選擇開發者後端，但後端未開啟	使用任一 AI 助理功能	顯示「目前連不上」的提示，App 其他功能照常	3/3 次正確提示且不當機

3.2.9 隱私與資料管理（F9）

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-9-1	任一已分析的照片	在照片頁選「移除 AI 分析資料」	該照片的分類、文字與影像特徵等分析資料全部移除，照片本身仍在「照片」App	見 QA-12：殘留 0 筆；照片仍存在 1/1
FT-9-2	在「照片」App 刪除 10 張已掃描的照片	回到 selfIE	這 10 張自動從 App 畫面與相簿消失	10/10 張在 5 秒內消失
FT-9-3	開啟「同步喜好項目」	在「照片」App 取消一張照片的喜好	App 同步取消；App 不會反過來修改「照片」App 的喜好項目	同步正確 10/10；修改系統喜好 0 次
FT-9-4	執行完 3.1～3.2 所有測試	比對測試前後相簿的照片張數、相簿數與檔案內容（雜湊值）	原始照片與相簿完全沒有變動	見 QA-09：變動 0 張

3.2.10 抽象語意搜尋（F10）

抽象語意搜尋包含三個部分，分別由下列測試案例驗證：

（1）建立場景圖：用手機上的 Apple Intelligence 分析照片，記錄照片中的主體、數量、關係、場景與氛圍（FT-10-5、FT-10-6）。

（2）文字型照片過濾：文字面積 ≥10% 的截圖、文件等照片不建場景圖，改用文字辨識（F5）與影像標籤（F1）產生照片類型，節省處理時間（FT-10-3、FT-10-4）。

（3）語意搜尋：把查詢句拆成主體、數量、關係與情境，先以整體語意相似度找出候選照片，再依數量、關係與照片類型細排（FT-10-1、FT-10-2）。

編號	測試條件	測試步驟	預期結果	Pass / Fail 標準
FT-10-	已完成建圖的測	1. 輸入查詢	正確照片排在前面	見 QA-13

1	試照片；事先標好正確照片的查詢，分 11 類（物體與動物、人物與數量、動作、空間關係、地點與場景、時間與光線、氛圍與情緒、事件、文字截圖文件、專有名詞、食物）	2. 檢查前 5 張結果		
FT-10-2	刻意加入的干擾照片，例如查「狗」時的狗玩偶、查「海邊」時的泳池	輸入對應的查詢	干擾照片排在正確照片之後	見 QA-13
FT-10-3	文字型照片（截圖、文件、講義、票券；文字面積 ≥10%）共 20 張	1. 執行建圖 2. 檢查處理方式 3. 用類型搜尋（如「考試題目」「新聞截圖」）	不呼叫 Apple Intelligence，直接以文字辨識與影像標籤產生紀錄；仍可被搜尋到	20/20 張未呼叫模型；搜尋準確度見 QA-15
FT-10-4	一般照片 20 張（含拍到少量文字的照片，如教室中的投影片）	執行建圖	文字不多的照片照常建場景圖，不被當成文字型照片	誤判為文字型 ≤1 張

3.3 介面測試

介面測試分成兩部分：使用者看到的畫面（UI），以及 App 與其他系統之間的連接（IF）。

表 3-2　介面測試項目

編號	測試條件	測試步驟	預期結果	Pass／Fail 標準
UI-01	已完成首次掃描	依序點選下方 5 個分頁（照片、相簿、Agent、我的、最愛），各重複 10 次	每次都正確切換，畫面不空白	50/50 次正確
UI-02	深色、淺色模式	在兩種模式下瀏覽所有分頁	文字與背景對比清楚，沒有看不見的文字	兩種模式各 5 個分頁，10/10 頁正常
UI-03	名稱很長的地點與清單（如「想去清單・日本東京都」）	檢查清單、相簿標題	重要文字不被「…」截斷到無法辨識	20 個長名稱中截斷到無法辨識 0 個
UI-04	介面與 AI 產生的文字	抽查 50 個畫面文字與 50 段 AI 產生內容	全部為繁體中文，稱呼使用「你／妳」	簡體字 0 個（見 QA-11）
UI-05	系統文字大小（預設與最大）	在 iPhone「設定」切換文字大小後，瀏覽首頁、照片頁、設定頁	版面完整，文字不重疊，按鈕可點選	2 種大小 × 3 頁，6/6 頁正常
IF-01	iPhone「照片」App（PhotoKit）	執行全部功能後檢查系統相簿	App 只讀取照片，不寫入、不刪除	寫入或刪除 0 次
IF-02	App 與開發者後端的連線（只測 App 端的處理）	在連線正常、斷線、逾時 30 秒三種情況使用 AI 助理	正常時顯示結果；斷線或逾時時顯示提示，其他功能照常	3 種情況 3/3 符合
IF-03	Google 地圖、Apple 地圖	從想去清單開啟地圖	兩者顯示同一地點	同 FT-8-3
IF-04	從其他 App（如瀏覽器）分享截圖到 selfIE	分享 5 張商品或店家截圖	自動整理進購物清單或想去清單	5/5 張被處理

3.4 績效測試

績效測試量測系統的反應時間、處理速度與資源用量。時間以 App 內記錄的時間戳記計算；「p95」代表 100 次中有 95 次低於此時間。

表 3-3　績效測試 KPI

編號	指標	測試條件	量測方式	Pass 標準
PF-01	搜尋反應時間	測試相簿 10,000 張；20 組查詢各執行 5 次	從按下搜尋到顯示結果的時間	p95 < 2 秒，且平均 < 1 秒
PF-02	篩選反應時間	同上，套用時間或地點篩選	從點選篩選到結果更新的時間	p95 < 0.5 秒
PF-03	首次掃描速度	10,000 張，App 保持在前景、接上電源	掃描總張數 ÷ 總時間	≥ 10 張／秒（10,000 張 ≤ 17 分鐘）
PF-04	自動分類速度	10,000 張已有影像特徵，更新分類設定後重新分類	重新分類完成所需時間	≤ 60 秒
PF-05	文字辨識速度	10,000 張中看起來像紙張、卡片的照片，App 在前景	已辨識張數 ÷ 時間	≥ 5 張／秒
PF-06	App 啟動時間	關閉 App 後重新開啟（已完成掃描）	點選圖示到首頁可操作的時間	< 3 秒（10 次平均）
PF-07	開啟相簿與照片	開啟 500 張的主題相簿、點開單張照片	點選到內容顯示的時間	< 1 秒（各 10 次，p95）
PF-08	AI 整理回憶筆記	30 張照片的旅行相簿	按下按鈕到筆記顯示的時間	手機上 AI ≤ 30 秒
PF-09	抽象搜尋反應時間	已完成建圖的測試相簿；10 組查詢各執行 5 次	從按下搜尋到顯示結果的時間（含查詢解析）	p95 < 3 秒

編號	指標	測試條件	量測方式	Pass 標準
PF-10	建圖速度	App 在前景、接上電源；一般照片與文字型照片各 50 張	每張平均處理時間	文字型照片每張 ≤ 1 秒（不呼叫模型）；一般照片記錄實測值，作為後續改善基準
PF-11	最近照片可搜尋時間	測試相簿首次建圖，App 在前景	從開始建圖到最近 100 張照片都可以搜尋的時間	≤60 分鐘

3.5 品質測試

品質測試評估辨識準確率、穩定性、可靠度與隱私安全。準確率指標的意義：**Precision（準確率）**是「被標上的照片中，真的屬於該分類的比例」，代表標錯得少；**Recall（召回率）**是「真的屬於該分類的照片中，被找到的比例」，代表漏掉得少；**F1** 是兩者的調和平均；**Accuracy** 是全部照片中分對的比例；另外，抽象語意搜尋使用排序指標是指： MRR 是「第一張正確照片排第幾名」的倒數平均（排第 1 名得 1 分、第 2 名得 0.5 分、第 3 名得 0.33 分），代表使用者多快看到想要的照片；nDCG@5 看前 5 張結果中正確照片的數量與位置，越前面分數越高，滿分都是 1。

表 3-4　品質測試 KPI

編號	指標	測試資料	量測方式	Pass 標準
QA-01	自動分類準確率（F3）	使用者在自己相簿標記的 4,467 筆＋Open Images V7 19,043 張、Places365 5,050 張、Food-101 2,025 張；78 個有分類判斷器的小分類	5 折交叉驗證，計算每個分類的 Precision、Recall、F1，再取平均（macro）；有使用者標記的分類只用使用者的照片驗證	Precision ≥ 90%、Recall ≥ 60%、F1 ≥ 70%；達標分類比例 ≥ 60%
QA-02	文字搜尋準確度（F2）	20 組查詢，人工標記每組的正確照片	Recall@20：前 20 張結果找到的正確照片 ÷ 該查詢正確照片數（最多 20）	Recall@20 ≥ 80%
QA-03	旅行相簿偵測（F6）	人工標記 10 次旅行	以「旅行」為單位計算 Precision、Recall、F1	F1 ≥ 80%
QA-04	專屬相簿比對（F7）	5 張範例，50 張正確照片＋無關照片	自動加入照片的 Precision	Precision ≥ 85%
QA-05	穩定性	連續操作 2 小時（搜尋、瀏覽、整理交替）；搜尋 1,000 次	當機（閃退）次數、錯誤次數	當機 0 次；搜尋錯誤 0 次
QA-06	中斷後恢復（可靠度）	掃描進行中強制關閉 App 10 次	重開後是否接續、張數是否正確	10/10 次接續；遺漏或重複 0 張
QA-07	原始照片安全	全部測試前後	照片張數、相簿數、檔案雜湊值比對	變動 0 張、0 本
QA-08	隱私：照片不離開手機	使用 F1～F7、F9 全部功能，用電腦監看網路流量	送出照片資料的次數	0 次（只有 F8 在同意後才可能送出）
QA-09	繁體中文輸出	抽查 50 段 AI 產生內容	出現簡體字的段數	0 段

編號	指標	測試資料	量測方式	Pass 標準
QA-10	移除 AI 資料完整性（F9）	20 張照片執行「移除 AI 分析資料」	資料庫中殘留的分析資料筆數；照片是否仍在	殘留 0 筆；20/20 張照片仍在
QA-11	抽象語意搜尋準確度（F10）	自有照片 124 張；查詢分為調整組與測試組，兩組不重疊，測試組不參與任何參數調整	11 類分別計算 MRR、nDCG@5 後取平均（macro）	測試組 MRR ≥ 0.80、nDCG@5 ≥ 0.70
QA-12	與基準方法比較（F10）	同 QA-13	與舊版（只比對場景圖）、純文字比對兩種方法比較 MRR	新版在調整組與測試組都高於兩種基準
QA-13	文字型照片不建圖後的準確度（F10）	同 QA-13 調整組	文字型照片改用文字辨識＋影像標籤後的 MRR，與全部建圖比較	MRR 下降 ≤0.02

4. 測試方法

本計畫以「黑箱測試」為主：測試人員依第 3 章的步驟操作 App，比對實際結果與預期結果。辨識準確率（QA-01）另以訓練與評估程式自動計算：程式用與 App 相同的影像辨識模型（MobileCLIP）取得照片的影像特徵，以使用者標記與公開資料集替每個分類訓練判斷器，再以 5 折交叉驗證統計 Precision、Recall 與 F1。抽象語意搜尋的準確度（QA-13～QA-15）另以 PC 端評估程式計算：先以 PC 原型為測試照片建立場景圖，再對已標好正確照片的查詢計算 MRR 與 nDCG@5；建圖加速方式則以同一份資料模擬，比較準確度變化。核心邏輯（分類規則、搜尋篩選、單據判斷等）另有自動化單元測試，在每次修改後執行。

4.1 測試環境需求

表 4-1　硬體與軟體環境

類別	項目	規格與說明
硬體	主要測試手機	iPhone 18 Pro Max（支援 Apple Intelligence，可測 F8 手機上 AI）
硬體	開發與評估電腦	Mac（Apple 晶片），用於安裝 App 與執行準確率評估程式、Windows 筆電，用於執行 PC 端原型與評估
軟體	開發工具	Xcode（含 Instruments，量測時間、記憶體）
軟體	評估程式	Python 3.12、Core ML 工具，執行與 App 相同的 MobileCLIP 模型，並訓練分類判斷器
軟體	抽象語意搜尋 PC 端	Python、Gemini API（建圖）、multilingual-e5-small（文字向量）、RapidOCR 與 MobileCLIP-S2（文字型照片模擬）、SQLite
軟體	抽象語意搜尋手機端	Foundation Models（建圖與查詢解析）、NLContextualEmbedding（文字向量）、SQLite
網路	網路監看	電腦上的封包監看工具，用於 QA-10

表 4-2　測試資料

資料	內容	用途
測試相簿	10,000 張以上的真實手機照片，包含旅行、美食、人物、截圖、票券等，事先備份	F1、F2、F6、績效測試
Open Images V7	Google 公開的影像資料集，每張照片附有人工標記的物件與場景類別；本次使用 19,043 張	QA-01 分類判斷器訓練與驗證
Places365	MIT 公開的場景資料集；本次使用 5,050 張（森林、機場、飯店等場景類）	QA-01 分類判斷器訓練與驗證
Food-101	101 種料理的公開資料集；本次使用 2,025 張（美食類）	QA-01 分類判斷器訓練與驗證

資料	內容	用途
使用者標記照片	在自己的相簿中用標記工具回答「是／不是」，共 4,467 筆，含 Open Images 沒有的類別（專輯與周邊、拍貼、手帳、課本、聊天截圖等）	QA-01 訓練與驗證（以此為主）
人工標記資料集	人物照 200 張、單據 100 張、20 組搜尋查詢、10 次旅行，各附正確答案	QA-02～QA-06
抽象語意搜尋標註資料	組員自有照片 124 張；調整組 30 條、測試組 15 條查詢，每條標好正確照片，並刻意加入干擾照片	QA-13～QA-15

4.2 測試項目的通過準則

（1）**單一測試項目**：實際結果符合預期結果，且達到該項目表格中的 Pass 標準（數值或次數），判定為 Pass；否則為 Fail。

（2）分類準確率（QA-01）：每個分類分別計算；Precision ≥ 90% 且 F1 ≥ 70% 的分類視為「達標」。整體以各分類平均（macro）判定。有使用者標記的分類以使用者自己的照片驗證；只有公開資料的分類以公開資料驗證，且必須達到 Precision ≥ 95%、Recall ≥ 30% 才放進 App。

（3）**時間類 KPI**：同一項目至少量測 20 次，以 p95（第 95 百分位）或平均值判定。

（4）**整體通過準則**：(1) 隱私與安全項目（QA-09、QA-10、QA-12）必須全部 Pass；(2) 功能測試 Pass 比例 ≥ 90%；(3) 績效與品質 KPI Pass 比例 ≥ 80%；(4) 不得有造成當機或資料遺失的未修正問題。

（5）**抽象語意搜尋（QA-13）**：以測試組各類別的平均 MRR 判定。測試組只在所有參數確定後評估一次，不用來調整參數，避免分數因過度調整而偏高。

4.3 測試中止的準則與再繼續的需求

中止準則：發生下列任一情況時立即停止測試：

（1）發現 App 修改、移動或刪除了任何原始照片或相簿。

（2）App 在同一流程連續當機 3 次以上，導致後續測試無法進行。

（3）測試環境異常（手機過熱、儲存空間不足）影響量測結果。

再繼續的需求：

（1）問題已修正並重新安裝 App，且修正後通過相關的自動化單元測試。

（2）照片相關的中止，必須從備份還原測試相簿，並重新執行 QA-09。

（3）重新執行中止當下的測試項目，以及受修改影響的相關項目（迴歸測試）。

4.4 測試交付項目

（1）系統測試計畫與成果報告（本文件）。

（2）測試案例清單（第 3 章各表）與測試紀錄表（含每次測試的實測值與判定）。

（3）分類準確率評估報告（各分類 Precision、Recall、建議門檻），以及評估程式與資料集對應表。

（4）人工標記測試資料集（人物照、單據、搜尋查詢、旅行）的答案檔。

（5）自動化單元測試程式與執行結果。

（6）問題追蹤紀錄（第 6.4 節）。

（7）抽象語意搜尋評估程式、標註工具與標註資料（查詢與正確照片），以及評估報告（各類別 MRR、nDCG@5、建圖加速實驗結果）。

5. 人員配置與訓練需求

5.1 測試人員配置

表 5-1　測試人員配置

人員	系所	負責項目
邱庭俞	人工智慧學系	F1～F9 的操作、功能、介面、績效與品質測試；分類準確率評估與分類判斷器訓練（QA-01）
鄭暐薰	人工智慧學系	F10 抽象語意搜尋：PC 端原型、評估程式與標註工具、標註資料集、手機端模組（建圖、文字型照片過濾與搜尋）；負責 FT-10、PF-11～PF-13、QA-13～QA-15 的測試。
湯依儒	資訊工程學系	
蔡佩妤	資訊工程學系	

5.2 訓練需求

（1）**App 操作**：所有測試人員需熟悉 selfIE 的各分頁、整理進度、設定與 AI 助理（約 1 小時）。

（2）**量測工具**：負責績效測試的人員需會使用 Xcode Instruments 量測時間與記憶體，以及網路監看工具（約 2 小時）。

（3）**準確率指標與人工標記**：了解 Precision、Recall、F1 的計算方式，並依同一套標記規則標記測試資料，標記不一致時由兩人討論決定。抽象語意搜尋的標註須依照片本身判斷正確答案，不可參考模型產生的描述，避免以模型的答案評估模型。

（4）**隱私與資料保護**：測試前備份測試相簿；不得以他人未同意的照片作為測試資料。

6. 測試結果與審查

6.1 測試結果摘要

表 6-1　KPI 測試結果

編號	指標	Pass 標準	實測值	判定
QA-01	自動分類 Precision（平均）	≥ 90%	94.5%	Pass
QA-01	自動分類 Recall（平均）	≥ 60%	65.9%	Pass
QA-01	自動分類 F1（平均）	≥ 70%	75.5%	Pass
QA-01	達標分類比例	≥ 60%	65.4%（51 / 78）	Pass
QA-02	搜尋 Recall@20	≥ 80%	95%	Pass
QA-03	旅行相簿 F1	≥ 80%	96.76%	Pass
QA-04	專屬相簿 Precision	≥ 85%	90%	Pass
QA-05	連續操作 2 小時當機次數	0 次	0 次	Pass
QA-06	中斷後接續	10/10 次	10/10 次	Pass
QA-07	原始照片變動	0 張	0 張	Pass
QA-08	未經同意送出照片	0 次	0 次	Pass
QA-09	AI 內容簡體字	0 段	0 段	Pass
QA-10	移除 AI 資料後殘留	0 筆	0 筆	Pass
QA-13	抽象語意搜尋 MRR（測試組）	≥ 0.80	0.93（PC 原型）	Pass
QA-13	抽象語意搜尋 nDCG@5（測試組）	≥ 0.70	0.80（PC 原型）	Pass
QA-14	與基準比較（MRR）	高於基準	調整組：新版 0.81 / 純文字 0.63 / 舊版 0.32；測試組：新版 0.93 / 純文字 0.74 / 舊版 0.64	Pass

編號	指標	Pass 標準	實測值	判定
QA-15	文字型照片不建圖後的 MRR 變化	≤ 0.02	-0.008	Pass
PF-01	搜尋反應時間 p95	< 2 秒	0.57 秒	Pass
PF-02	篩選反應時間 p95	< 0.5 秒	0.43 秒	Pass
PF-03	首次掃描速度	≥ 10 張 / 秒	165.385 秒	Pass
PF-04	重新分類 9055 張	≤ 60 秒	54.751 秒	Pass
PF-05	文字辨識速度	≥ 5 張 / 秒	2.63 張 / 秒	Fail
PF-06	App 啟動時間	< 3 秒	2.38 秒	Pass
PF-07	開啟相簿與照片 p95	< 1 秒	0.77 秒	Pass
PF-08	AI 回憶筆記（手機上 AI）	≤ 30 秒	8.84 秒	Pass

功能、操作與介面測試（FT、OP、UI、IF）的結果，依各案例的 Pass / Fail 標準記錄於測試紀錄表，並在此彙整 Pass 比例（整體通過準則：≥ 90%）。

6.2 自動分類準確率評估結果

測試方式：第三輪以前，App 以文字描述和照片的影像特徵比對分數來分類（第三輪：123 類平均 Precision 90.6%、Recall 42.9%，Recall 未達標）。本輪改為替每個分類訓練一個「分類判斷器」：以 MobileCLIP 取得照片的影像特徵，用自己相簿標記的 4,467 筆資料，加上 Open Images V7（19,043 張）、Places365（5,050 張）與 Food-101（2,025 張）公開資料訓練，並以 5 折交叉驗證選出 Precision 達 90% 的門檻。判斷器只負責「很確定是」與「一定不是」的照片，中間的照片仍用文字描述比對。

放進 App 的條件：使用者標記足夠（是、不是各 15 張以上）的分類，只在使用者自己的照片上驗證，公開資料只在不降低 Recall 時才加入；只有公

開資料的分類必須達到 Precision ≥ 95%、Recall ≥ 30%；需要照片文字佐證的分類（收據發票、機票與登機證）不會只靠公開資料。結果共 78 個小分類放進 App（44 個以使用者照片驗證、34 個只有公開資料），其餘 44 個小分類沒有判斷器，照舊以文字描述比對。

整體結果：78 個放進 App 的分類，平均 Precision 94.5%、Recall 65.9%、F1 75.5%，三項都達到目標；其中 51 類同時達到 Precision ≥ 90% 與 F1 ≥ 70%（65.4%）。以使用者照片驗證的 44 類平均 Precision 93.6%、Recall 69.5%，其中 19 類 Recall ≥ 80%；只有公開資料的 34 類平均 Precision 95.5%、Recall 61.3%，但這是在網路照片上驗證的，放到使用者的照片上通常會差一些。和第三輪相比 Recall 提高約 23 個百分點，但兩輪的測試資料與分類範圍不同，只能作為參考。

表 6-2　各大分類的平均準確率（分類判斷器，5 折交叉驗證）

大分類	判斷器 / 小分類	Precision	Recall	F1	達標分類
美食與飲品	16 / 17	94.1%	56.9%	69.1%	9
動物	8 / 9	95.6%	76.8%	83.4%	7
風景與自然	7 / 9	91.4%	77.1%	82.0%	6
人物與生活紀錄	2 / 6	93.5%	83.5%	87.5%	2
旅遊與地點	5 / 11	95.4%	68.0%	78.7%	4
電影與藝文	4 / 6	95.0%	59.5%	72.2%	2
音樂與表演	2 / 7	95.5%	39.5%	55.6%	0
動漫與遊戲	4 / 7	96.5%	58.5%	66.6%	2
收藏與手作	6 / 10	94.3%	58.2%	71.4%	4
休閒與節慶	4 / 4	95.8%	66.2%	76.0%	2
運動與戶外	6 / 14	95.5%	69.8%	79.1%	5
穿搭與美妝	4 / 7	95.5%	77.8%	82.5%	3

大分類	判斷器／小分類	Precision	Recall	F1	達標分類
學習與工作	7 / 7	93.4%	66.4%	75.9%	3
購物與生活管理	2 / 6	91.5%	68.0%	77.4%	1
3C 與相機	1 / 2	95.0%	76.0%	84.4%	1
全部（平均）	**78 / 122**	**94.5%**	**65.9%**	**75.5%**	**51**

表現最好的分類包括：水族（Precision 100% / Recall 100%）、髮型（100% / 100%）、聖誕節（97% / 100%）、派對聚會（92% / 97%）、桌遊（95% / 95%）與美妝（94% / 94%）；以使用者照片驗證、Recall ≥ 80% 的 19 類還包括電影、貓、狗、花、森林、漫畫、夜市、服飾等。**表現最差的**是電玩與夾娃娃（20%）、整桌餐點（27%），以及炸物、包包、麵包烘焙（皆 29%），這些分類的畫面差異大，判斷器只在很有把握時才標上。

仍待改善的部分：

（1）**沒有判斷器的分類**：建築外觀、家具、居家空間、人物照、海報、地標、夜景等 31 類只有公開資料，但網路照片太雜，在 Precision 95% 時 Recall 太低（或準確率不足），所以沒有放進 App；拍貼、商品與貨架、收據發票 3 類的使用者標記不夠。這些分類仍以文字描述比對，本輪沒有重新評估，需要使用者標記自己的照片後才能訓練。

（2）**驗證範圍有限**：以使用者照片驗證的數字來自同一個相簿，換成其他使用者的相簿時可能較低；判斷器以 Precision 90% 選門檻、每張照片最多自動分 3 類，分數不夠確定的照片改由使用者在「待確認」回答，回答後的標記可再用來訓練判斷器（FT-3-2）。

6.3 抽象語意搜尋評估結果

測試方式：以 PC 原型為 124 張組員自有照片建立場景圖，查詢依類別

分為調整組（30 條）與測試組（15 條），調整組用於調整參數，測試組只在最後評估一次。比較三種方法：舊版（只比對場景圖的主體與關係）、純文字比對（把照片描述與查詢逐字比較），以及新版混合式搜尋（先以整體語意相似度從全部照片找出候選，再以數量、關係、照片類型細排）。

整體結果：新版在兩組都明顯高於兩種基準（表 6-3）。舊版只要查詢的用詞和場景圖不同（例如查「溫馨」，但場景圖寫的是「家人圍坐吃飯」）就找不到；新版先用整體語意找出候選照片，所以換一種說法也找得到，再用數量與關係細排，區分「一個人」和「兩個人」、「人遛狗」和「狗追人」。

表 6-3　抽象語意搜尋準確度

方法	調整組 MRR	調整組 nDCG@5	測試組 MRR	測試組 nDCG@5
舊版（只比對場景圖）	0.32	0.27	0.64	0.51
純文字比對	0.63	0.50	0.74	0.57
新版（混合式）	**0.81**	**0.73**	**0.93**	**0.80**

各比對面向的貢獻：加入主體比對後，兩組的分數都明顯提升，是最主要的改進（表 6-4）。加入數量比對後，調整組的 nDCG@5 由 0.69 提升至 0.71，但測試組的 MRR 由 0.96 降為 0.93；逐題檢查後發現，主要原因是「一碗麵」的「一碗」被解析為數量 1，使含有多碗麵的照片被扣分（見 B-17）。修正量詞解析後，數量比對的效果可望提升。

表 6-4　各比對面向的貢獻(改成缺什麼)

使用的比對面向	調整組 MRR	調整組 nDCG@5	測試組 MRR	測試組 nDCG@5
只用整體語意	0.72	0.64	0.91	0.74
＋主體比對	0.81	0.69	0.96	0.84
＋數量	0.81	0.71	0.93	0.79

使用的比對面向	調整組 MRR	調整組 nDCG@5	測試組 MRR	測試組 nDCG@5
＋關係與類型（完整版）	0.81	0.73	0.93	0.80

建圖加速：手機上以 Apple Intelligence 建圖約 30 秒／張，8000 張需要約 66 小時，且 App 不在前景時模型使用量會受系統限制。截圖、文件、講義、票券這類照片，使用者通常以類型搜尋（如「考試題目」「新聞截圖」），而不是以畫面內容搜尋，因此測試讓這類照片不建場景圖，改用其他功能已有的結果：以文字辨識（F5）判斷是否為文字型照片（文字面積 ≥10%），再以 MobileCLIP 影像標籤（F1）作為照片類型。

表 6-5　文字型照片處理方式比較（調整組，16 張文字型照片）

處理方式	是否呼叫模型	整體 MRR	文字截圖類 MRR
全部建場景圖（基準）	是	0.812	0.73
只存文字辨識結果	否	0.746	0.01
簡短建圖（類型＋描述＋一個主體）	是（輸出較短）	0.809	0.69
文字辨識＋影像標籤第一名	否	0.792	0.51
文字辨識＋影像標籤前 3 名	**否**	**0.804**	**0.61**

只存文字辨識結果會讓文字型照片幾乎搜不到，因為照片上的文字通常不包含「收據」「考題」這類類型名稱；加入影像標籤前 3 名後，整體 MRR 僅下降 0.008，且完全不需要呼叫模型，因此手機版採用此方式。文字型照片的判斷只能靠文字辨識：影像標籤會把 33 張一般照片誤判為海報、截圖等文字類型（例如拉麵合照被判成菜單）。文字辨識拿不到文字面積時，改以字數 ≥ 200 字判斷，與面積判斷的 16 張中有 14 張一致。

限制：本評估的照片與查詢數量有限（124 張照片，調整組 30 條、測試組 15 條查詢，文字型照片 16 張），且測試組沒有「時間與光線」類的查詢，因此測試組只涵蓋 10 類。各方法間 0.03 以內的差距可能只來自一兩條查詢

的排名變化。手機端使用 Apple Intelligence 後的準確度與速度，將於 PF-11～PF-13 實測。

6.4 開發期間發現的問題與處理

以下為開發與試用期間發現、已完成修正的問題。修正後需在第 4.5 節第 6 階段執行迴歸測試確認。

表 6-4　問題紀錄

編號	發現的問題	原因	處理方式	對應測試
B-01	菜單、手寫筆記被列為「麵食」待確認	照片上的菜名文字被當成分類線索	看起來像紙張、或文字有「菜單」時，菜名不再當成菜色線索；既有的錯誤待確認自動重新整理	FT-3-4
B-02	玩偶、周邊被分成貓狗；狗被同時標成貓	動物門檻調得太低；動物種類可同時標多種	門檻調回 0.23；像玩偶、公仔、小卡時不標動物；同一張只標最像的一種動物	FT-3-5
B-03	「家庭合照」與「多人合照」分不出來	照片無法看出人與人的關係	移除「家庭合照」，手動加過的照片移到「人物照」	FT-4-1
B-04	自拍、合照分類不準	影像模型分不出人數；改用人臉偵測後手機發燙，人形立牌、看板上的臉也被算進去	移除人臉偵測：自拍改用 iPhone「自拍」相簿；單人、雙人、多人合照合併為「人物照」，並排除周邊、海報、看板與螢幕上的人	FT-4-1～4-4
B-05	「照片」App 的喜好項目不會馬上同步	最愛頁不會自動更新；同步排在較慢的工作之後	同步完成即更新畫面，並優先同步	OP-04
B-06	長時間整理時手機發燙	多項分析同時進行、沒有休息	依手機熱狀態自動放慢或暫停，降溫後接續	PF-10、OP-05

編號	發現的問題	原因	處理方式	對應測試
B-07	手機上 AI 產生不存在的價格、帳號名稱	語言模型憑空補內容	價格必須在照片文字中與貨幣符號相鄰才採用；店名必須出現在照片文字中	FT-8-4
B-08	AI 筆記超過手機上模型的長度上限而失敗	一次送入所有照片描述	改成每天各整理一次再合併	FT-8-1
B-09	AI 輸出出現簡體字	模型輸出未固定字體	所有 AI 輸出統一轉為繁體中文	QA-11
B-10	同一店家的品牌與分店被列成兩筆；Google 與 Apple 地圖位置不同	名稱未合併；兩種地圖用不同查詢方式	合併品牌與分店；兩種地圖使用相同查詢與座標	FT-8-2、8-3
B-11	早餐店牆上的價目表、掛彩色吊燈的小吃店被分到「KTV」	價目表、彩色吊燈的畫面和 KTV 包廂的描述很像	加入「餐廳價目表、早餐店」等排除描述；生日派對與 KTV 合併為「派對聚會」，並以使用者標記訓練判斷器	FT-3-1
B-12	電影票根常被漏掉，但搜尋「電影票根」卻找得到	票根是獨立分類、訓練資料少，票根上的文字也沒有用來判斷	票根與電影院合併為「電影」；看起來像紙張、文字又有影廳、座位、場次等電影字詞時，直接分到「電影」	FT-5-1
B-13	公告、文件被分到「收據發票」	文字出現「收據」「統一編號」就判斷為收據	必須有收據格式才算：發票號碼（兩個英文字母＋8 位數字）或金額欄位（總計、找零…），並同時有發票、收據等字詞	FT-5-2、FT-5-5
B-14	小卡、壓克力立牌、吧唧、鑰匙圈與專輯分不清；櫻花與花、盲盒與公仔也常混淆	外觀太接近，影像特徵分不出來	合併為「專輯與周邊」；櫻花併入「花」、盲盒併入「公仔」；舊分類的手動結果自動移到新分類	FT-3-1、FT-3-5

編號	發現的問題	原因	處理方式	對應測試
B-15	搜尋「泰國」只找到 90 張，要輸入「曼谷」才找得到其他照片	名稱叫「泰國」的地區被當成地點，只比對到那個地區	名稱和國家相同的地區不列為地點，輸入國家名時比對整個國家	FT-2-6
B-16	搜尋「2026 年 8 月」後，地點篩選列出該月沒去過的地方；輸入「2026/8」找不到照片	地點選項沒有依已選的日期過濾；查詢解析不認得數字日期	篩選選項依其他已選條件連動，該月沒有照片時提示最接近的月份；支援「2026/8」等數字日期	FT-2-2、FT-2-4、FT-2-6
B-17	掃描完成後，抽象語意搜尋的建圖進度停在「0 / 7,409」	建圖要等分類結果的提示，重新分類時一直等不到；一張照片失敗會擋住後面的照片	分類提示最多等 2 秒，逾時先用現有資料建圖；改成逐張處理，失敗的照片跳過	PF-13
B-18	抽象語意搜尋的結果時多時少	相似度門檻混用不同模型建的圖來校準	只用同一個模型建的圖校準，並設上限 0.85；搜尋前自動補建與校準	QA-13

6.5 審查結論與後續改善

結論：

截至本報告撰寫時，F1～F9 已完成開發與開發期間的功能驗證，分類準確率（QA-01）已完成評估：改用分類判斷器後，78 個有判斷器的分類平均 Precision 94.5%、Recall 65.9%、F1 75.5%，達標分類比例 65.4%，QA-01 四項指標都達到 Pass 標準，Recall 由第三輪的 42.9% 明顯提高。開發期間發現的 18 個問題（表 6-3）已修正，修正後仍需依第 4.5 節第 6 階段執行迴歸測試。

後續改善：

（1）**擴充使用者標記**：沒有判斷器的 44 個分類（如建築外觀、家具、人物照、海報），以及 Recall 仍低於 50% 的分類（如整桌餐點、炸物、包包），用標記工具補足「是／不是」各 15 張以上後重新訓練。

（2）**以其他相簿驗證**：目前以使用者照片驗證的數字來自單一相簿，下一輪請其他測試人員標記自己的相簿，確認判斷器在不同使用者的相簿中的表現。

（3）**善用使用者回饋**：鼓勵使用者回答「待確認」，以實際相簿持續學習，並在下一輪測試比較回答前後的 Recall。

（4）**抽象語意搜尋**：修正量詞解析（B-17）；精簡場景圖的輸出格式，進一步縮短一般照片的建圖時間；擴充測試照片與查詢，並加入只能靠關係分辨的干擾照片；在影像標籤清單中補齊文字類標籤（如講義課本），提升文字型照片的辨識。